


Pipeline Parallelism cho các Model vượt giới hạn Memory của Single-GPU

Benchmark thực tế: DeepSpeed Pipeline vs. PyTorch Pipelining vs. Single-GPU Gradient Checkpointing




Course:	Distributed & Parallel Training (GenAI Master) – Topic 2
Hardware:	2× NVIDIA T4 GPUs (16GB VRAM)
Model:	gpt2-xl (1.5B parameters)
Dataset:	WikiText

Thành viên nhóm

Sinh viên	MSSV
Giáp Tiến Dũng	20250471E
Nguyễn Lương Duy	20250649E
Nguyễn Hoàng	20250130E
Nguyễn Hà Phú Thịnh	20241623E



Vấn đề của VRAM




Model	Params	Memory	Fit 1 T4?
gpt2-xl	1.5B	~24 GB	No
opt-2.7b	2.7B	~43 GB	No
opt-6.7b	6.7B	~107 GB	No

Cả 3 model đều OOM với 1 card **NVIDIA T4 (16GB)**


Giải pháp: Thu nhỏ **memory footprint** hoặc chia model qua nhiều **GPUs**

4 bài toán cần giải quyết



D1 - Enablement

Khả năng huấn luyện:
Có thể train một model (opt-2.7b) vốn không thể fit trên 1 GPU hay không?




D2 - Frameworks

Đổi đầu công nghệ:
PyTorch pipelining so với DeepSpeed Pipeline Parallelism – ai vượt trội hơn?



D3 - The Bubble


Tối ưu Pipeline: Số lượng micro-batch ảnh hưởng thế nào đến thời gian idle (bubble) và throughput?



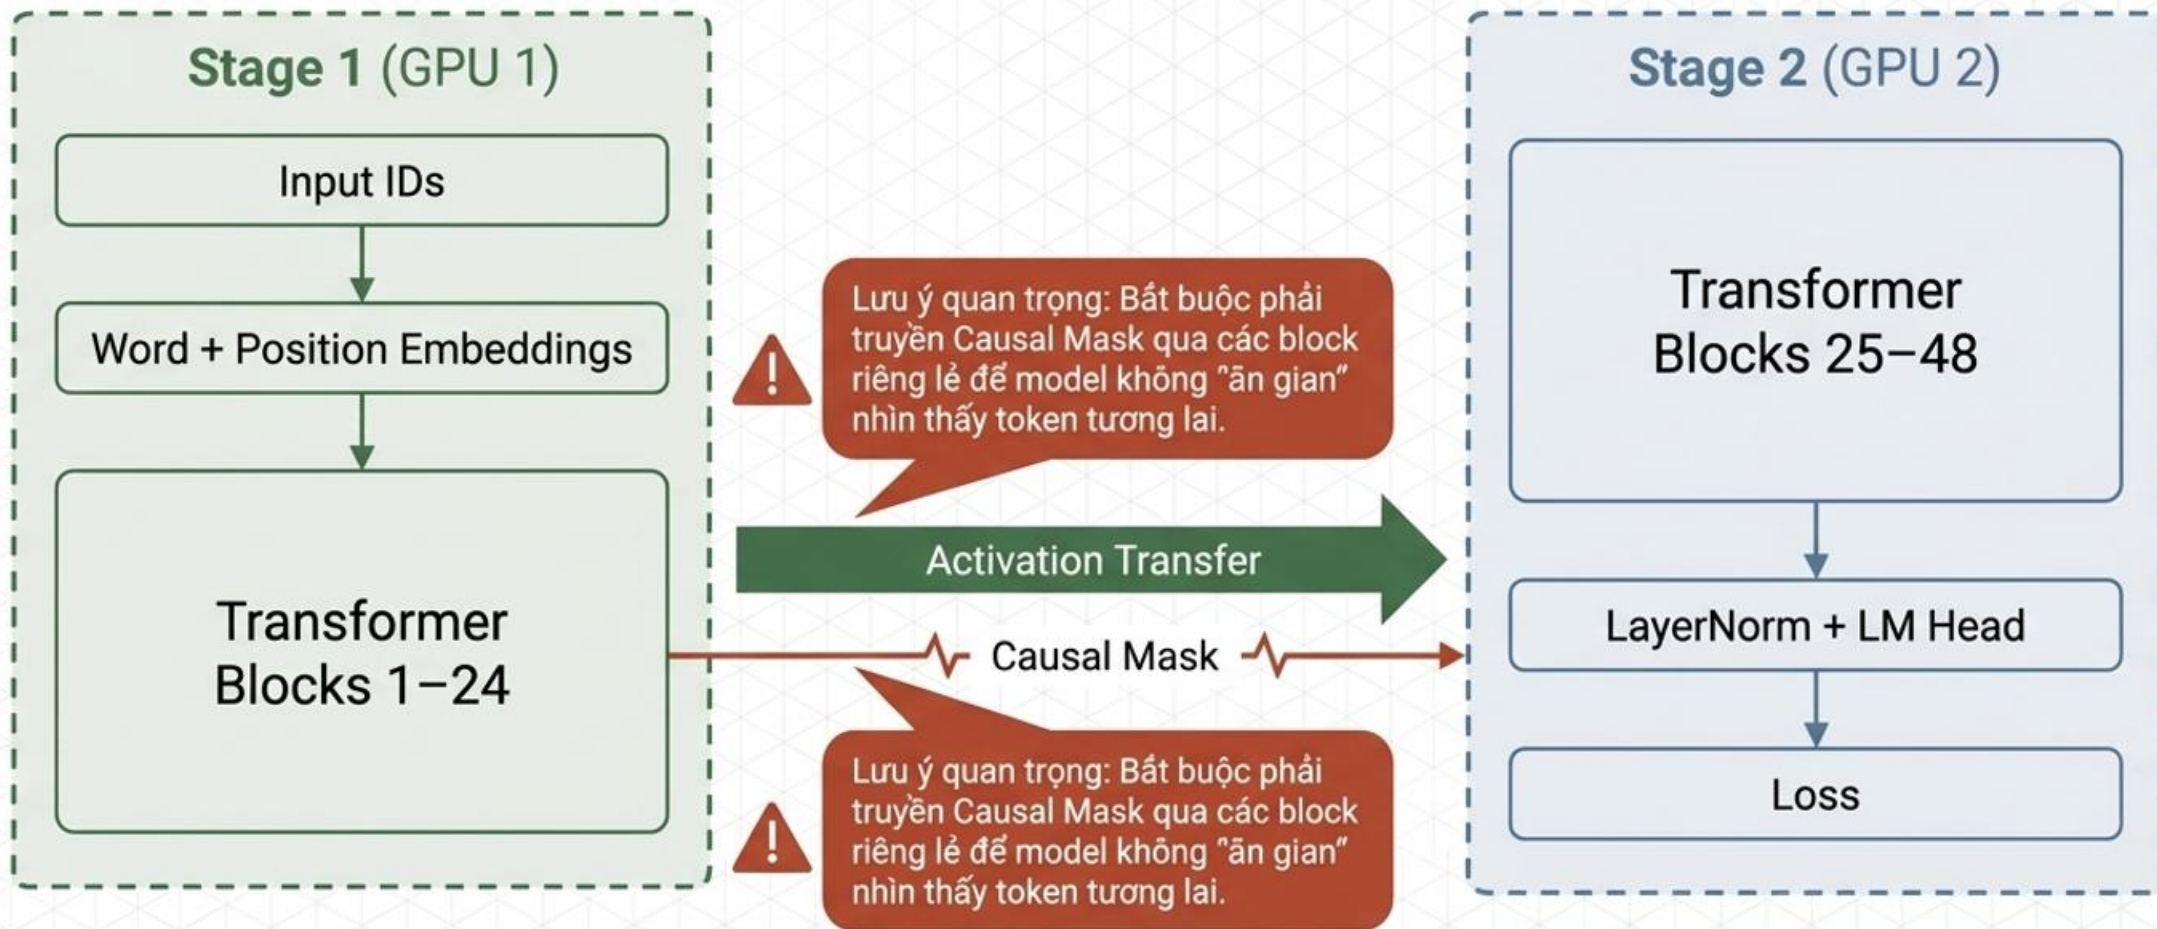
D4 - 2 vs 1 GPU

So sánh tổng thể:
2 GPU chạy pipeline có thực sự tốt hơn 1 GPU dùng gradient checkpointing?

Pipeline Parallelism




Tách gpt2-xl thành 2 Pipeline Stages



Micro-batch và pipeline bubble

Thời gian idle không thể tránh khỏi



Bản chất: Là khoảng thời gian GPU bị bỏ trống khi chờ pipeline nạp đầy hoặc xả cạn.


Công thức: $Bubble = (P - 1) / (M + P - 1)$. Với 2 GPU, $bubble = 1 / (M + 1)$.

Micro-batches (M)	Bubble %
1	50%
2	33%
4	20%
8	11%
16	5.9%

Thực tế: Tăng số lượng micro-batch (M) sẽ nén phần không gian đỏ này lại, giúp tăng throughput tổng thể.

Experimental Setup

Phần cứng (Hardware)



Mô hình & Dữ liệu (Model & Dataset)



Model: gpt2-xl (1.5B) & opt-2.7b



Dataset: WikiText (Sequence length: 512)

Hệ thống so sánh (Systems Compared)

- PyTorch torch.distributed.pipelining
- DeepSpeed Pipeline Parallelism
- Single-GPU + Gradient Checkpointing

Chỉ số (Metrics)



Thông lượng (Tokens/sec)



Peak Memory (GB/GPU)




Pipeline Bubble (%)



Training Loss

Deliverable 1 – Enablement

One T4 (16GB)



VRAM


Model: opt-2.7b

Out of Memory



Memory win

Two T4 Pipeline (32GB)



65%



VRAM

65%



VRAM

Model: opt-2.7b

Trains successfully

1,701 tokens/sec
10.6 GB/GPU

Đây là lợi ích rõ nhất của pipeline parallelism.

- Pipeline không chỉ để tăng tốc, mà trước hết để giải quyết giới hạn memory.
- Model được chia ra hai GPU nên mỗi GPU chỉ giữ một phần model.

Deliverable 2 — DeepSpeed vs. PyTorch

	 PyTorch pipelining	 DeepSpeed PP
Throughput	1,835 tok/s	1,656 tok/s
Memory/GPU	8.4 GB	11.5 GB
MFU	14.5%	13.1%
Final loss	2.65	2.76
Schedules	GPipe → ZBV	1F1B only
Loss scaling	Manual	Automatic

Kết luận:


PyTorch nhanh hơn và dùng ít memory hơn, phù hợp cho nghiên cứu schedule. DeepSpeed tiện hơn vì nhiều thứ được tự động hóa, phù hợp khi muốn triển khai nhanh, ổn định.

Deliverable 3 — Micro-batches and the bubble


M	Theory bubble	PyTorch tok/s	PyTorch GB/GPU	DeepSpeed tok/s	GPipe GB/GPU
1	50%	—	—	689	—
2	33%	1,281	6.9	1,015	7.3
4	20%	1,605	8.4	1,353	11.1
8	11%	1,835	8.4	1,656	OOM
16	5.9%	1,959	8.4	1,869	n/a



Deliverable 3 — Micro-batches and the bubble




Deliverable 3 — Micro-batches and the bubble



Deliverable 3 — Micro-batches and the bubble

Schedule ladder: ZBV nhanh nhất nhưng chỉ +6.2%



Deliverable 4 – Two GPUs vs. one GPU

System	Throughput	Memory/GPU
One GPU, no checkpointing	OOM	—
One GPU + checkpointing	~1,221 tok/s corrected	12.2 GB
Two GPUs, PyTorch 1F1B	1,835 tok/s	8.4 GB
Two GPUs, DeepSpeed 1F1B	1,656 tok/s	11.5 GB

- **Hai GPU** PyTorch pipeline nhanh hơn single GPU khoảng **1.5x**.
- **Memory** trên mỗi GPU thấp hơn vì model được chia đôi.
- **Không** đạt 2x do bubble và PCIe communication overhead.
- **Quan trọng nhất:** pipeline train được model mà single GPU không thể fit.

Honesty Note Box ⓘ

Lưu ý minh bạch:
Single-GPU baseline có bug đo throughput, đã được sửa bằng hệ số $\times 8$ vì lượng data mỗi step bị đếm thiếu.

1

Pipeline giúp fit model lớn hơn một GPU

opt-2.7b OOM trên 1 T4 nhưng train được trên 2 T4.

2

Micro-batch giảm bubble, nhưng lợi ích giảm dần

Tăng M giúp throughput tăng, nhưng overhead PCIe vẫn tồn tại.

3

Trên 2×T4 PCIe: memory win lớn, speed win vừa phải

Khoảng 1.5× nhanh hơn single GPU, không phải magic 2×.

Limitations

- Chỉ có 2 GPU T4, PCIe, không NVLink
- Micro-batch sweep chưa giữ global batch cố định
- Run còn ngắn; PyTorch PP chưa có perplexity eval
- Single-GPU throughput cần correction $\times 8$

Future work

- Chạy trên GPU có NVLink hoặc nhiều hơn 2 stages
- Sweep M với fixed global batch size
- Longer training để kiểm tra convergence
- Thử model lớn hơn và schedule mới hơn